

电类工程导论(C类)实验1 报告

贾萧松 516030910548

| | |
|---------------|-----|
| 一、 实验概述..... | 1 - |
| 二、 实验环境..... | 1 - |
| 三、 实验内容..... | 1 - |
| 1. 实验 1..... | 1 - |
| 2. 实验 2..... | 2 - |
| 3. 实验 3..... | 2 - |
| 四、 问题与解决..... | 4 - |
| 五、 总结..... | 5 - |

一、 实验概述

本次实验中，主要内容为通过学习 html 基本知识，python 库 BeautifulSoup 的使用以及正则表达式的基本知识来实现对网页信息的获取。

二、 实验环境

Ubuntu14.04+python2.7+BeautifulSoup4

三、 实验内容

1. 实验 1

给定任意网页内容，返回网页中所有链接地址（不包括图片地址），并将结果打印至文件 res1.txt 中，每一行为一个链接地址。

首先调用 urlopen 函数读取指定 url 并用 read 函数获取代码

```
content = urllib2.urlopen(url).read()
```

然后创建 BeautifulSoup 对象，创建储存结果的 set

```
urlset = set()
soup = BeautifulSoup(content)
```

接着使用 findAll 函数得到所有标签名为'a'的标签并获得其'href'的内容

```
for i in soup.findAll('a'):
    tmp = str(i.get('href', ' '))
```

此时从得到的结果看获取的内容有部分不是链接，有部分链接不规范（例如：“//www.baidu.com”），在此我给所有链接加入了“http://”开头

```
if(tmp != ' '): #make all url begin with http://
    if(tmp[:2] == "//"):
        tmp = "http:" + tmp
    elif(tmp[:1] == '/' and len(tmp) >= 3):
        tmp = "http:" + tmp
    elif(tmp[0] == 'w' and len(tmp) >= 3):
        tmp = "http://" + tmp
    elif(tmp[0] == 'h'):
        res += (tmp + "\n")
    urlset.add(tmp)
```

最后把结果加入 set 并写入文件

```
urlset.add(tmp)
f.write(res)
f.close();
return urlset
```

2. 实验 2

给定任意网页内容，返回网页中所有图片地址，并将结果打印至文件 res2.txt 中，每一行为一个图片地址。

代码主体与实验 1 相同，只是获取的是标签名为“img”的“src”属性

```
for i in soup.findAll('img'):
    tmp = str(i.get('src', ' '))
```

3. 实验 3

给定糗事百科有图有真相任意一页内容，返回网页中图片和相应文本，以及下一页的网址，并将图片地址与相应文本以下述格式打印至文件 res3.txt 中，每一行对应一个图片地址与相应文本，格式为：图片地址\t相应文本

首先，获取糗事百科的访问权限

```
req = urllib2.Request(url, None, {'User-agent': 'Custom User Agent'})
```

然后读取，创建 beautifulsoup 对象

```
content = urllib2.urlopen(req).read()
soup = BeautifulSoup(content)
```

通过观察网页 html 代码，发现我们要找的内容都在 id 为'qiushi_tag_数字'的 div 标签下

```

overflow: hidden; visibility: hidden; display: none;";...
▶<div id="header" class="head">...</div>
▼<div id="content" class="main">
  ▼<div class="content-block clearfix">
    ▼<div id="content-left" class="col1">
      ▶<div class="article block untagged mb15" id=
        "qiushi_tag_119554204">...</div>
      ▶<div class="article block untagged mb15" id=
        "qiushi_tag_119554168">...</div>
      ▶<div class="article block untagged mb15" id=
        "qiushi_tag_119554166">...</div>
      ▶<div class="article block untagged mb15" id=
        "qiushi_tag_119554155">...</div>
      ▶<div class="article block untagged mb15" id=
        "qiushi_tag_119554129">...</div>
      ▶<div class="article block untagged mb15" id=
        "qiushi_tag_119554105">...</div>
      ▶<div class="article block untagged mb15" id=
        "qiushi_tag_119554153">...</div>
      ▶<div class="article block untagged mb15" id=
        "qiushi_tag_119554083">...</div>
      ▶<div class="article block untagged mb15" id=
        "qiushi_tag_119554144">...</div>
      ▶<div class="article block untagged mb15" id=

```

具体的，图片的地址在每个 qiushi_tag 下 class 为 'thumb' 的 div 标签下，只需获取其 a 标签的 "href" 内容

```

▼<div class="article block untagged mb15" id=
  "qiushi_tag_119554204">
  ▶<div class="author clearfix">...</div>
  ▶<a href="/article/119554204" target="_blank" class=
    "contentHerf">...</a>
  ▼<div class="thumb">
    ▶<a href="/article/119554204" target="_blank">...</a>
  </div>

```

而文字内容在这里

```

▼<div class="article block untagged mb15" id=
  "qiushi_tag_119554082">
  ▶<div class="author clearfix">...</div>
  ▼<a href="/article/119554082" target="_blank" class=
    "contentHerf">
    ▼<div class="content">
      ▼<span>
        "程先生"
        <br>
        <br>
        "《在人间》"
        <br>
        "2017.9.17"
      </span>
    </div>
  </a>

```

根据以上，写出下面这段代码

```

soup = BeautifulSoup(content)
for qiu pic in soup.findAll('div', {'id':re.compile('^qiushi tag \d+')}):
    qiushi_tag = str(qiu pic.get('id',' ')[11:])
    sentence = str(qiu pic.find('div',{'class':'content'}).span.text)
    pic = 'http:'+str(qiu pic.find('div',{'class':"thumb"}).find('a').find('img').get('src',' '))
    docs[qiushi_tag] = {"content":sentence, "imgurl":pic}

```

用正则匹配找到 qiushi_tag,并获取数字部分

注意到文字部分可能有多行，直接使用 get 函数不是很方便，于是经过阅读文档，我找到了 text 成员。这个成员忽略了所有标签，只保留文本，也就是我们要找的内容。

接下来，获取下一页的 url，观察到在这里

```

<li>
  <a href="/pic/page/2?s=5018770" rel="nofollow">
    <!--<a href="/pic/page/2/" rel="nofollow">-->
    <span class="next">
      下一页
    </span>
  </a>
</li>
</ul>
</div>

```

如果直接一层一层找到这里是繁琐的，于是我采用找到 `span` 标签, `class` 属性为“next”的标签，再找它的 `parent` 的方法，很简单的实现了要求。

由于获取的是相对地址，所以使用到了 `urljoin` 函数将相对地址转换为绝对地址

```

url = "https://www.qiushibalke.com/pic"
nextpage = urlparse.urljoin(url, soup.find('span', {'class': 'next'}).parent.get('href', ''))

```

四、问题与解决

在本次实验中，我遇到的最大的问题就是在实验 3 中文的输入输出，这也是使用 `python2.7` 经常会遭遇到的问题。

经过网上的查询和学习，我总结了如下几点，并应用这些知识解决了这个问题

1. 编码分为 `ascii`(单字节), `unicode`(双字节), `utf8`(变长字节)，而在 `python` 中，建议程序过程中统一使用 `unicode` 编码，保存文件和读取文件时使用 `utf8`

2. `python` 默认使用 `ascii` 编码去解释源文件。如果源文件中出现了非 `ASCII` 码字符，不在开头声明 `encoding` 会报错。我们可以声明为 `utf8`，告诉解释器用 `utf8` 去读取文件代码，这个时候源文件有中文也不会报错。

3. 在编程过程中推荐设置相应的默认编码为 `utf8`；读文件拿到 `str` 类型：`str -> decode('utf8') -> unicode`；程序处理：用 `unicode`；写文件：`unicode -> encode('utf8') -> str`，用 `str` 类型写入文件

根据以上知识，写出下面的代码

```

# coding = utf8
import sys, os
reload(sys)
sys.setdefaultencoding('utf-8')

```

```

http://pic.qiushibalke.com/system/pictures/11955/119554345/medlun/app119554345.jpg 闲来无事信手之作，不喜勿喷。从经典口号“天王盖地虎，宝塔镇河妖”这个年代过来的摸百老人扶我上高楼！
http://pic.qiushibalke.com/system/pictures/11955/119554362/medlun/app119554362.jpg 自动厨房，不错。
http://pic.qiushibalke.com/system/pictures/11955/119554351/medlun/app119554351.jpg 今天刚看到的新闻，泡妞就泡妞吧，拿人家手机就成犯罪了
http://pic.qiushibalke.com/system/pictures/11955/119554275/medlun/app119554275.jpg 谁知道医生写的什么？？在线急等

```

写中文到文件

除此之外，即使你设置了默认的编码为“`utf-8`”，此时 `print string` 没问题，但如果 `print` 字典（`dic`）和元组（`tuple`）还是会编码错误（因为内置的 `print` 函数的一些问题）。于是我就直接去掉转义字符`\`，然后打印出来，问题得到解决。

```
content = urllib2.urlopen(req).read()
print str(parseQiushibaikePic(content)).decode('string_escape')
```

去掉转义符后 print

```
jia@jia-VirtualBox:~/Desktop/JIa/hw1$ python 3.py http://www.qiushibaike.com/pic
({'119554220': {'content': '\xe4\xba\x94\xe6\x98\x9f\xe5\xa5\xbd\xe8\xaf\x84\xef
\xbc\x81', 'imgurl': 'http://pic.qiushibaike.com/system/pictures/11955/119554220
/medium/app119554220.jpg'}, '119554254': {'content': '\xe4\xb8\xad\xe7\xa7\x8b\x
```

未设置之前, 直接 print docs

```
jia@jia-VirtualBox:~/Desktop/JIa/hw1$ python 3.py http://www.qiushibaike.com/pic
({'119554220': {'content': '五星好评!', 'imgurl': 'http://pic.qiushibaike.com/s
ystem/pictures/11955/119554220/medium/app119554220.jpg'}, '119554254': {'content
': '中秋节, 我告诉孩他爸整点实在的, 结果.....', 'imgurl': 'http://pic.qiushibaike.c
om/system/pictures/11955/119554254/medium/app119554254.jpg'}, '119554345': {'con
tent': '闲来无事信手之作, 不喜勿喷。从经典口号“天王盖地虎, 宝塔镇河妖”这个年代过
```

设置之后, print docs

五、总结

通过本次实验, 我学习到了: ubuntu 的基本使用方法, html 的入门知识, 正则表达式的入门知识以及用 python 获取网页内容的方法和一些注意点; 与此同时, 在调试程序, debug 的过程中, 我也感觉到自己编程的能力得到了提升。

最后, 感谢老师和助教们的耐心教导和辛勤付出!

贾萧松 516030910548

2017.9.17